# BountyLine: Propuesta de procesos ETL

Universidad El Bosque · Ingeniería de Sistemas · Bases de datos 2

Gabriella Michelle Castro Cuello
Lina Sofía Patiño Calderón
Julian Samuel Rodriguez Hernandez
Bogotá D.C., noviembre de 2026

## 1. Elección del modelo

Para BountyLine se propone utilizar el modelo estrella. El modelo copo de nieve normalizaría las dimensiones en varias tablas relacionadas (por ejemplo, zona, región y país), y sería útil cuando las jerarquías fueran pesadas o cambiaran con frecuencia. Para este proyecto se considera que ese no sería el caso, por lo que la estrella daría un diseño más simple, con consultas más directas y sería más fácil de explicar.

## 2. Justificación

- **Las jerarquías son planas:** La dimensión de zona tiene nombre y nivel de peligro, sin una cadena de niveles geográficos que justifique separarla. Lo mismo ocurre con especialidad y con cazarrecompensas. Normalizar esas dimensiones solo añadiría tablas y uniones sin aportar nada.
- **Las consultas son el caso típico de estrella.** Las consultas que se plantearían (ingresos por mes, recompensa promedio por zona y especialidad, días de cierre por rango de reputación) cruzarían un hecho con una o dos dimensiones. En estrella sería una unión directa a cada dimensión; en copo de nieve serían cadenas más largas y más fáciles de equivocarse.
- **El volumen esperado sería pequeño.** El argumento clásico a favor del copo de nieve es ahorrar espacio, y en este proyecto el espacio no sería un factor importante. Lo que se buscaría es que el modelo fuera fácil de entender para el equipo y para quien evalúe el proyecto.

- **Es una opción común para analizar.** Herramientas de inteligencia de negocios como Power BI o Metabase pueden trabajar bien con esquemas en estrella, y el modelo podría explicarse en una sola figura: hechos al centro y dimensiones alrededor.

Se propone una denormalización deliberada: en dim_cazarrecompensas se guarda zona_base como texto en lugar de una llave hacia dim_zona. Esto sería una decisión propia de la estrella, ya que se aceptaría cierta redundancia a cambio de consultas más simples.

## 3. Cuándo se consideraría el copo de nieve

Si BountyLine creciera con jerarquías reales, por ejemplo zonas agrupadas en regiones y regiones en países, con muchas fuentes de datos y necesidad de no repetir textos, la dimensión de zona se normalizaría en dim_zona, dim_region y dim_pais. Ese escenario no formaría parte del alcance actual, por lo que se plantearía únicamente como una posible evolución futura.

## 4. Propuesta de implementación

El modelo se plantea como una propuesta de estrella, por lo que, si en el futuro se implementara el Data Warehouse, se deberían definir las siguientes reglas.

### 4.1 Grano de cada tabla de hechos

- *fact_mision: se propondría una fila por misión.*
- *fact_movimiento: se propondría una fila por movimiento de billetera.*
- *fact_actividad: se propondría una fila por evento de la bitácora.*

Si una tabla mezclara granos distintos, las sumas podrían salir duplicadas. Por eso se propondría resumir las postulaciones con COUNT dentro de fact_mision y no cargarlas como filas aparte.

### 4.2 Llaves sustitutas

*dim_tiempo usaría id_fecha como entero con formato AAAAMMDD. Las demás dimensiones podrían usar las mismas llaves naturales de MySQL, ya que sería suficiente para la propuesta de este proyecto. Como mejora futura, se podrían asignar llaves propias del DW, de modo que un cambio de ID en el sistema operativo no afectara el análisis.*

### 4.3 Orden de carga

Si se implementara el proceso ETL, se propondría que sp_etl_transformar primero cargara las dimensiones y después los hechos, para que las llaves foráneas pudieran encontrar su fila.

### 4.4 Valores faltantes

Una misión sin cazarrecompensas asignado no debería quedar fuera del análisis. Se podría crear una fila especial en la dimensión con llave -1 y utilizar ese valor en lugar de NULL:

```
INSERT INTO dim_cazarrecompensas
VALUES (-1, 'Sin asignar', NULL, NULL, 'SIN_DATOS');

-- en fact_mision:
COALESCE(m.id_cazarrecompensas, -1)
```

### 4.5 Correcciones al proceso ETL

Para una posible implementación del proceso ETL, se deberían considerar tres puntos antes de realizar la carga:

- **Desfase horario.** La bitácora guardaría fechas en UTC y fact_actividad debería convertirlas a hora de Bogotá restando 5 horas. La dimensión de tiempo debería aplicar la misma conversión al calcular su fecha inicial; de lo contrario, los eventos de madrugada caen en un día que no existe en dim_tiempo y se pierden al unir.
- Staging vacío. Si una tabla de staging no tiene filas, el MIN devuelve NULL y LEAST también. Se podría envolver cada MIN con COALESCE para evitar que la carga **fallara.**
- **Cazarrecompensas sin cuenta.** La unión con stg_cuenta debería ser LEFT JOIN, para evitar que algún cazarrecompensas desapareciera de la dimensión.

```
SELECT DATE(LEAST(
  COALESCE((SELECT MIN(fecha_publicacion) FROM stg_mision), CURDATE()),
  COALESCE((SELECT MIN(fecha) FROM stg_movimiento), CURDATE()),
  COALESCE((SELECT MIN(fecha) - INTERVAL 5 HOUR FROM stg_bitacora), CURDATE()))) AS f
```

### 4.6 Validación propuesta de la estrella

Si se implementara la carga, se podrían realizar las siguientes comprobaciones:

- Verificar los valores de texto reales, porque si no coinciden las consultas regresan cero filas sin mostrar error: SELECT DISTINCT estado FROM stg_mision, y lo mismo para el tipo de movimiento y el tipo de bitácora.
- Ninguna misión debe quedar sin zona en la dimensión:

```
SELECT COUNT(*) FROM fact_mision m
LEFT JOIN dim_zona z ON z.id_zona = m.id_zona
WHERE z.id_zona IS NULL;
```

- Los totales de pagos deben coincidir entre el DW y MySQL:

```
SELECT SUM(monto) FROM fact_movimiento WHERE tipo = 'PAGO';
SELECT SUM(monto) FROM bountyline.movimiento WHERE tipo = 'PAGO';
```

Si la primera consulta devolviera un valor distinto de cero, significaría que existe una llave huérfana. Si los dos totales no coincidieran, significaría que la carga podría haber perdido o duplicado filas.

### 4.7 Documentación en el repositorio

Se propondría incluir en el repositorio un diagrama con los tres hechos al centro y las cuatro dimensiones alrededor, junto con una tabla con el grano de cada hecho. Ambos elementos permitirían justificar la decisión de diseño de forma visual.